Universidad del Caribe

Visualización de datos

La economía del entretenimiento: Netflix y tendencias globales

Fase 1 — Análisis

Documento de justificación

Equipo: 🥃

Integrantes:

Axel Rebolledo Cordova

🥃

Repositorio: github.com/Axlreb28/dashboard_visualizacion

9 de noviembre de 2026

1. Introducción

Este documento describe y justifica las actividades de la Fase 1 (Análisis) del proyecto *"La economía del entretenimiento: Netflix y tendencias globales"*. El proyecto consiste en un dashboard dinámico desarrollado en React, con una base de datos PostgreSQL, que analiza el catálogo de Netflix para comprender las tendencias de producción, los géneros más populares y la distribución geográfica del contenido.

La fuente de datos es el dataset público **Netflix Movies and TV Shows** (Kaggle, autor: Shivam Bansal), que contiene **8,807 títulos** y **12 variables**. Todas las cifras de este documento se obtuvieron perfilando el archivo original con el script `scripts/perfilado.py` incluido en el repositorio, de modo que el plan de preprocesamiento se basa en problemas reales observados en los datos, no en supuestos.

2. Análisis de la audiencia

2.1 ¿Quiénes son los usuarios?

Usuario	Perfil	Prioridad
Dirección de estrategia de contenido (plataforma de streaming)	Directivos que definen en qué mercados, idiomas y géneros invertir a varios años.	Principal
Analistas de negocio y de licenciamiento	Preparan propuestas de adquisición y producción original; necesitan comparar países, géneros y años.	Secundaria
Investigadores y público académico (negocios y cultura digital)	Estudian la globalización del entretenimiento y la diversidad cultural del catálogo.	Secundaria

Se eligió como usuario principal a la dirección de estrategia de contenido porque los KPIs solicitados (títulos por país, evolución anual, géneros y directores dominantes) responden a preguntas de **asignación de inversión a largo plazo**, no de operación diaria.

2.2 ¿Qué decisiones tomarán?

- **Expansión regional:** identificar mercados con alta producción local (India, Corea del Sur, España, México) frente a mercados subrepresentados.
- **Mezcla de contenido:** decidir la proporción de películas vs. series y qué géneros reforzar o reducir.
- **Alianzas creativas:** detectar directores y regiones con producción recurrente para acuerdos de largo plazo.
- **Lectura de tendencias:** reconocer cuándo creció o se desaceleró la incorporación de títulos (p. ej., auge 2016–2019).

2.3 Nivel de detalle requerido

La audiencia principal necesita una **vista agregada**: totales, rankings (Top 5) y tendencias anuales. El detalle a nivel de título individual no es necesario en la vista principal, pero sí conviene ofrecer **filtros** (tipo de contenido, rango de años, país) y un **tooltip** o tabla de detalle para que los analistas puedan profundizar (drill-down) sin saturar la vista general. La granularidad temporal mínima será el

año; el mes solo se usará como dato derivado.

3. Definición de objetivos

> **Objetivo general:** Visualizar la evolución (2008–2021) y la distribución geográfica y temática del catálogo de Netflix para identificar tendencias globales de producción y cómo varían los gustos por región y año, apoyando decisiones estratégicas de inversión en contenido.

¿Qué problema resuelve? El catálogo crudo es una lista de miles de títulos con campos de texto multivalor (varios países, géneros y directores en una sola celda), fechas en texto y datos faltantes. Así es imposible responder rápidamente preguntas como "¿qué países aportan más contenido?" o "¿en qué años se aceleró el crecimiento?". El dashboard convierte ese catálogo en indicadores comparables y visuales.

Objetivos específicos e indicadores

Objetivo específico	KPI	Visualización
Conocer la distribución geográfica de la producción	Número de títulos por país	Mapa de calor (coroplético) por país
Analizar la evolución temporal del catálogo	Lanzamientos por año (año de estreno y año de incorporación)	Gráfico temporal de líneas/áreas
Identificar los géneros dominantes	Top 5 géneros	Nube de palabras de géneros + barras Top 5
Identificar a los creadores más productivos	Top 5 directores	Gráfico de barras horizontales
Comparar la mezcla de formatos	% películas vs. series	Gráfico circular (dona)

Valores de referencia obtenidos en el perfilado (datos sin limpiar, sirven como línea base):

Indicador	Valor observado
Total de títulos	8,807 (6,131 películas = 69.6 %; 2,676 series = 30.4 %)
Países distintos	122 — Top: EE. UU. 3,690 · India 1,046 · Reino Unido 806 · Canadá 445 · Francia 393
Géneros distintos	42 — Top: International Movies 2,752 · Dramas 2,427 · Comedies 1,674 · International TV Shows 1,351 · Documentaries 869
Directores más productivos	Rajiv Chilaka 22 · Jan Suter 21 · Raúl Campos 19 · Marcus Raboy 16 · Suhas Kadav 16
Rango de estreno / incorporación	Estreno 1925–2021 · Incorporación a Netflix: ene-2008 a 25-sep-2021

4. Preprocesamiento de datos

4.1 Identificación y entendimiento de variables

Variable	Significado	Formato original	Formato destino / uso
show_id	Identificador único del título	Texto (s1…s8807)	Llave primaria

Variable	Significado	Formato original	Formato destino / uso
type	Tipo de contenido	Categórica: Movie / TV Show	Categórica → KPI tipo de contenido
title	Nombre del título	Texto	Texto (detalle)
director	Director(es)	Texto multivalor separado por comas	Tabla puente título–director → Top 5
cast	Reparto	Texto multivalor	Se conserva; no se usa en KPIs
country	País(es) de producción	Texto multivalor	Tabla puente título–país → mapa
date_added	Fecha de incorporación a Netflix	Texto “September 25, 2021”	DATE + año y mes derivados
release_year	Año de estreno original	Entero	Entero → serie temporal
rating	Clasificación por edad	Categórica (TV-MA, PG-13…)	Categórica (filtro)
duration	Duración	Texto “90 min” / “2 Seasons”	Valor numérico + unidad
listed_in	Géneros	Texto multivalor	Tabla puente título–género → nube y Top 5
description	Sinopsis	Texto libre	Se conserva (detalle)

4.2 Diagnóstico de calidad

Variable	Nulos	%	Otros problemas detectados
director	2,634	29.9 %	Varios directores por celda
country	831	9.4 %	1,320 filas con varios países; 5 con coma final (“France,”)
cast	825	9.4 %	Multivalor
date_added	10	0.1 %	88 fechas con espacio inicial; 14 títulos con año de incorporación anterior al de estreno
rating	4	<0.1 %	3 registros con la duración escrita en rating (“74 min”, “84 min”, “66 min”)
duration	3	<0.1 %	Los mismos 3 registros: el valor quedó desplazado a rating
Duplicados	—	—	0 duplicados por show_id ni por título + tipo + año

4.3 Proceso de limpieza

El criterio general es: **no eliminar registros** si el título conserva información útil para algún KPI; en su lugar se imputa una etiqueta explícita y se excluye solo del indicador afectado. Así los totales generales siguen siendo consistentes con el catálogo real.

#	Paso	Acción y justificación
1	Normalizar texto	Leer en UTF-8 (conserva acentos como “Raúl Campos”); aplicar trim a todas las columnas de texto y quitar comas finales en country.
2	Corregir campos desplazados	En los 3 registros de Louis C.K., mover “74/84/66 min” de rating a duration y asignar rating = “NR”. Es un error de captura evidente, no un valor faltante.
3	Nulos en director (29.9 %)	Imputar “Desconocido”. Se excluye del Top 5 de directores, pero el título cuenta en los demás KPIs. Eliminar las filas descartaría casi un tercio del catálogo (sobre todo series).

#	Paso	Acción y justificación
4	Nulos en country (9.4 %)	Imputar “Desconocido”. No se pinta en el mapa; se muestra aparte como “sin país” para transparencia.
5	Nulos en date_added (10)	Se conservan con NULL; se excluyen solo de la serie “incorporaciones por año”. Siguen contando en la serie por año de estreno.
6	Nulos en rating (4) y cast (825)	rating → “NR” (No Rated, categoría ya existente). cast se deja NULL: no participa en ningún KPI.
7	Conversión de fechas	date_added a tipo DATE (formato %B %d, %Y).
8	Campos multivalor	Separar country, listed_in y director por coma en tablas puente (relación muchos a muchos). Así, una coproducción EE. UU.–Canadá cuenta para ambos países.
9	Inconsistencia de fechas (14)	Títulos con año de incorporación < año de estreno: se conservan y se marcan con fecha_inconsistente = true; se excluyen de métricas de antigüedad.

4.4 Columnas derivadas

Columna	Cálculo	Uso
year_added, month_added	Año y mes de date_added	Serie temporal de incorporaciones
decade	floor(release_year / 10) * 10	Agrupar estrenos antiguos
duration_value, duration_unit	Número y unidad (min / season) extraídos de duration	Análisis de duración
duration_category	Película: corta (<40 min), estándar (40–150), larga (>150)	Tratamiento de atípicos
antiguedad_al_agregar	year_added − release_year	¿Netflix agrega contenido nuevo o de catálogo?
genre_group	Unifica géneros equivalentes entre películas y series (“Dramas” + “TV Dramas” → “Drama”)	Nube de palabras y Top 5 sin duplicar conceptos
es_coproduccion	Número de países > 1	Análisis de colaboración internacional

4.5 Manejo de valores atípicos

Se usa el método del **rango intercuartílico (IQR)**: un valor es atípico si está fuera de [Q1 − 1.5·IQR, Q3 + 1.5·IQR]. La decisión de eliminar, ajustar o conservar depende de si el valor es **imposible** (error) o **plausible** (dato real extremo):

Variable	Hallazgo	Decisión
release_year	Q1 = 2013, Q3 = 2019 → límite inferior 2004; 719 títulos anteriores (mínimo 1925)	**Conservar.** Son clásicos reales del catálogo. En el gráfico temporal se usará eje completo con zoom/filtro de rango por defecto 2000–2021.
duration (películas)	Q1 = 87, Q3 = 114 min; 450 atípicos; 26 películas < 20 min y 3 > 240 min (máx. 312, película interactiva)	**Conservar y categorizar** con duration_category (cortometrajes y especiales son contenido legítimo).
duration (series)	Máximo 17 temporadas	**Conservar** (series de larga duración reales).
rating	3 valores “XX min”	**Ajustar:** son errores de captura; se corrigen (paso 2).

Variable	Hallazgo	Decisión
year_added	2008–2014 con menos de 25 títulos/año; 2021 solo hasta 25-sep	**Conservar y anotar:** refleja el inicio del streaming; 2021 se marca como año parcial para que la caída no se malinterprete.
Fechas inconsistentes	14 títulos agregados antes de su estreno	**Conservar y marcar** (flag); excluir solo de antigüedad_al_agregar.

Ningún registro se elimina: no se encontraron valores imposibles que no pudieran corregirse.

4.6 Integración de datos en la base de datos

Se eligió **PostgreSQL** alojado en **Supabase** (plan gratuito) porque: (1) los datos son relacionales y las relaciones muchos-a-muchos (título–país, título–género, título–director) se modelan de forma natural con tablas puente; (2) los KPIs son agregaciones (GROUP BY, COUNT, ranking) que SQL resuelve eficientemente con vistas; y (3) Supabase expone una API REST y un cliente JavaScript que React puede consumir directamente desde Vercel o GitHub Pages sin construir un backend propio.

Modelo de datos (normalizado):

Tabla	Columnas principales
titles	show_id (PK), type, title, date_added, year_added, month_added, release_year, rating, duration_value, duration_unit, duration_category, description, fecha_inconsistente
countries / title_countries	country_id (PK), name · (show_id, country_id)
genres / title_genres	genre_id (PK), name, genre_group · (show_id, genre_id)
directors / title_directors	director_id (PK), name · (show_id, director_id)

Flujo ETL:

- **Extracción:** descarga de netflix_titles.csv desde Kaggle.
- **Transformación:** script Python/pandas que aplica los pasos 4.3–4.5 y genera un CSV por tabla.
- **Carga:** creación del esquema (DDL) y carga con COPY/importador de Supabase; verificación de conteos (8,807 títulos, 122 países, 42 géneros).
- **Consumo:** vistas SQL por KPI (vw_titulos_por_pais, vw_lanzamientos_por_anio, vw_top_generos, vw_top_directores, vw_tipo_contenido) leídas por React con la llave pública de solo lectura (Row Level Security).

5. Selección del tipo de dashboard

Criterio	Operativo	Táctico	Estratégico (elegido)
Frecuencia de datos	Tiempo real / diaria	Semanal / mensual	**Anual / histórica**
Horizonte de análisis	Hoy	Meses	**Años (2008–2021)**
Usuario típico	Operador	Gerente de área	**Alta dirección**
Tipo de pregunta	¿Qué está pasando ahora?	¿Cómo vamos frente a la meta?	**¿Hacia dónde va el mercado?**
¿Lo soporta el dataset?	No: es una foto estática	Parcial: no hay metas ni métricas de desempeño (vistas, ingresos)	**Sí**

Se seleccionó un dashboard estratégico por las siguientes razones:

- **Naturaleza de los datos:** el dataset es una instantánea histórica del catálogo (hasta septiembre de 2021), sin actualización en tiempo real; un dashboard operativo no tendría datos que monitorear.
- **Ausencia de metas de desempeño:** no hay visualizaciones, ingresos ni objetivos mensuales, que son la base de un dashboard táctico.
- **Tipo de KPIs:** títulos por país, evolución anual y rankings de géneros/directores describen tendencias de largo plazo, propias de la visión estratégica.
- **Audiencia y decisiones:** la dirección de estrategia de contenido decide expansión regional y mezcla de catálogo a varios años, exactamente lo que se busca en la conclusión del proyecto: “observar tendencias globales y cómo los gustos varían por región y año”.

En consecuencia, el diseño priorizará pocas métricas de alto nivel en la parte superior (tarjetas KPI), visualizaciones de tendencia y distribución, y filtros simples (tipo, rango de años, país) en lugar de alertas o actualizaciones en vivo.

6. Siguientes fases

Fase	Actividades
2 — Preparación de datos	Implementar el script de limpieza, crear el esquema en Supabase y cargar los datos; validar conteos.
3 — Desarrollo	Construir el dashboard en React (tarjetas KPI, mapa, serie temporal, nube de palabras, gráfico circular, filtros).
4 — Despliegue	Publicar en Vercel o GitHub Pages desde el repositorio público y documentar en README.